

# 具數值強健性與原生解釋性之二維旋轉狀態空間模型 (2D Rot-SSM) 開發：應用於皮膚癌影像之高精準度自動化診斷

學 生：亞洲大學資訊工程學系三年級 藍家鎧

指導教授：亞洲大學資訊工程學系副教授 柯賢儒

## 一、摘要

本計畫針對後 Transformer 時代之長序列視覺建模瓶頸，聚焦於皮膚癌（如黑色素瘤）影像之高精準度自動化篩檢，提出一種具備數值強健性與原生解釋力之「二維旋轉狀態空間模型 (2D Rot-SSM)」。

臨床上，皮膚病灶之辨識高度仰賴病灶邊緣不規則性與全域結構對稱性之判讀，現有架構如卷積神經網路 (CNN) 受限於局部感受野，而變換器 (Transformer) 之運算複雜度隨影像解析度呈二次方 ( $O(N^2)$ ) 增長，難以兼顧全域建模能力與邊緣設備之推論效率。儘管近期 Mamba 類模型 [3] 以線性複雜度  $O(N)$  取得突破，但在醫療影像之邊緣部署環境下，常面臨有限字長 (Finite Word-Length, FWL) 產生之量化誤差，導致系統極點偏移甚至發散，缺乏長期運算之穩定性與臨床可信度。本研究之核心創新在於結合指導教授提出之 \*\*Rot-IIR 重參數化技術\*\*。

不同於傳統之事後優化方法，本計畫透過結構化設計，將狀態空間模型 (SSM) 之動態核心參數化為具備物理語義之極點半徑  $\rho$ 、頻率角度  $\theta$  與增益  $g$ 。藉由在訓練全程實施穩定半徑  $\rho < 1$  之強制約束，從而確保系統在數學層面具備絕對之 \*\*BIBO 穩定性\*\* (Bounded-Input Bounded-Output)。

此外，針對視覺數據之二維空間特性，本研究採用 \*\*2D Pseudo-separable (偽分離)\*\* 架構實作四向平行掃描，以極低之運算成本達成病灶全域對稱性特徵之提取，並解決了 Mamba-2 在擴展至高解析度影像時之記憶體頻寬瓶頸。本計畫利用 ISIC 2019 Challenge 之 25,331 張臨床影像進行驗證，並依據病患 ID 執行嚴謹之層級化數據分割，以防止數據洩漏。實驗預期將證明 2D Rot-SSM 在維持領先之診斷精準度 (AUC-ROC) 之同時，能透過極點分布圖與二維頻譜響應分析，將 AI 的抽象特徵轉化為臨床醫師可理解的頻域指標（如邊緣碎裂紋理之高頻響應）。本計畫成果預期將建立具備可診斷性與工程可重現性之結構化 AI 設計範式，為高可靠度醫療 AI 與行動診斷終端提供關鍵之理論驗證與實務價值。

## 二、研究動機和目的

### 2.1 研究動機

皮膚癌（如黑色素瘤）是全球發病率極高的惡性腫瘤，其早期診斷高度依賴醫師對病灶「ABCD」法則（非對稱、邊緣不規則、顏色不均、直徑）之判讀。從訊號處理觀點而言，精準擷取病灶的全域空間特徵 (Global Receptive Field) 與邊緣高頻紋理，是區分良惡性病變之關鍵。然而，現有卷積神經網路 (CNN) 受限於局部感受野，而視覺變換器 (ViT) 之運算複雜度隨解析度呈二次方 ( $O(N^2)$ ) 增長，難以兼顧全域建模能力與邊緣醫療設備之推論時效。

進入「後 Transformer 時代」，儘管最新的 Mamba-2 模型 [3] 透過優化記憶體與 I/O 頻寬，在維持線性複雜度  $O(N)$  的同時顯著提升了運算吞吐量，但在臨床應用中仍存在數值穩定性之隱憂。Mamba 類架構之輸入相依 (Input-dependent) 特性，使其在邊緣端執行有限字長 (FWL) 運算時，微小的量化誤差極易透過遞迴路徑放大，導致系統極點偏移甚至發散。這種「數值不穩定性」不僅會造成診斷結果失效，更使 AI 成為缺乏物理根據之黑盒系統。因此，如何繼承 Mamba-2 的高效能，並透過結構化重參數化（如 Rot-IIR）確保模型具備可保證之穩定性與可診斷性，是當前智慧醫療影像分析亟待填補的技術斷層（如表 1 所示）。

### 2.2 研究目的

本計畫旨在結合指導教授提出之「Rot-IIR 重參數化」與「穩定裕度約束」理論，針對皮膚病變判讀開發具備線性複雜度與結構性穩定之「二維旋轉狀態空間模型 (2D Rot-SSM)」，具



(a) 臨床 ABCD 判讀法則

| 特性     | ViT      | Mamba-2 | 2D Rot-SSM |
|--------|----------|---------|------------|
| 複雜度    | $O(N^2)$ | $O(N)$  | $O(N)$     |
| I/O 優化 | 一般       | 極高      | 高          |
| 數值穩定   | 低        | 中 (未約束) | 極高 (結構保證)  |
| 可診斷性   | 低        | 低       | 高 (具頻域意義)  |

表 1：視覺骨幹技術規格對比

圖 1：臨床診斷需求與前沿架構分析

體目標如下：

- 建構高效能 2D Pseudo-separable 建模機制**：利用四向旋轉平行掃描，在維持  $O(N)$  線性複雜度之前提下，達成與 Mamba-2 相當之運算效率，並精確捕捉高解析度影像中之全域非對稱特徵。
- 實作結構化數值強健性保證**：不同於傳統事後優化，本研究透過將 SSM 核心重參數化為旋轉極點模組，在訓練全程實施極點半徑  $\rho < 1$  之強制約束，確保模型在有限精度量化的環境下具備 **\*\*BIBO 穩定性\*\***，保證診斷結果之工程可重現性。
- 建立具物理意義之臨床診斷工具**：將訓練權重還原為具備物理語義之極點分布與頻譜響應，將 AI 的抽象特徵轉化為醫師可理解的頻帶指標（如偵測邊緣碎裂之高頻特徵），解決醫學 AI 之黑盒問題，提升臨床決策的可信度。

### 三、文獻回顧及探討

本章節針對本計畫核心技術涉及的四個主要領域進行文獻探討：(1) 深度學習在皮膚病變診斷中的應用進展，(2) 視覺 Transformer 與編碼效能演進，(3) 結構化狀態空間模型 (SSM) 的發展脈絡，及 (4) 有限字長效應對遞迴系統的影響。

#### 3.1 深度學習在皮膚病變診斷中的臨床應用

皮膚癌的早期診斷高度依賴醫師對病灶視覺特徵的判讀，其中「ABCD 法則」(Asymmetry 非對稱性、Border 邊界不規則、Color 顏色不均、Diameter 直徑) 為臨床金標準。Esteva 等人 [2] 在 Nature 發表之里程碑式研究指出，經過 129,450 張臨床影像訓練之深度卷積神經網路 (CNN)，其黑色素瘤診斷精準度已可與 21 位皮膚科專家相當，在 melanoma vs. nevus 二元分類中達成 90% 以上之 AUC-ROC。然而，該研究採用 Google Inception v3 架構，受限於 CNN 之局部感受野設計，在捕捉全域病灶對稱性與邊緣結構時仍存在理論瓶頸。

更近期之 Tschandl 等人 [9] 透過 HAM10000 數據集 (10,015 張 dermatoscopy 影像) 之建構，展示了多源資料整合與層級化診斷標籤對模型泛化性的重要性。該研究強調，臨床數據之不平衡性 (病患 ID 重疊、診斷類別分布不均) 若未適當處理，會導致模型過度擬合特定病患的皮膚背景特質，而非真正學習病理特徵。本計畫採用 ISIC 2019 (25,331 張影像) 並依據 patient-wise 分割之設計，正是延續此一最佳實踐。

#### 3.2 從卷積到視覺 Transformer：感受野與運算複雜度的權衡

傳統 CNN 受限於固定之局部感受野，難以在全域層面捕捉病灶之非對稱特徵。Vision Transformer (ViT) [1] 引入 Self-Attention 機制，理論上每個 patch 能與全圖所有 patch 互動，突破了 CNN 之感受野限制。然而，Self-Attention 之計算複雜度為

$O(N^2)$  [1] ( $N$  為序列長度)，對於高解析度醫療影像（如 ISIC 之  $1022 \times 767$  像素）而言，運算成本與記憶體需求成為邊緣部署之瓶頸。此一矛盾構成「後 Transformer 時代」之核心驅動力。

### 3.3 結構化狀態空間模型 (SSM) 的理論進展

#### 3.3.1 從 S4 到 Mamba：線性複雜度的實現

Gu 等人 [4] 提出之 S4 (Structured State Space Sequence Model) 首次將古典控制論中之線性時不變 (LTI) 狀態空間模型應用至深度學習。S4 透過特殊參數化 (低秩修正 + Cauchy 核) 將 SSM 之運算複雜度從  $O(N^2L)$  降低至  $\tilde{O}(N+L)$ ，在 Long Range Arena 基準測試中達成 SoTA，特別是在 Path-X (序列長 16,384) 等超長序列任務上取得突破。S4 之核心貢獻在於證明，適當參數化之狀態空間模型能以線性複雜度達成與 Transformer 相當之長程依賴建模能力。

Gu 與 Dao [3] 進一步引入「選擇機制」(Selection Mechanism)，使 SSM 參數成為輸入相依函數。與傳統時不變 SSM 不同，Mamba 之動態參數  $\Delta$ 、 $\mathbf{A}$ 、 $\mathbf{B}$  根據當前輸入而變化，使系統能選擇性地傳播或遺忘資訊。結合硬體感知之平行掃描演算法 (避免 GPU 記憶體層級間之 I/O 瓶頸)，Mamba 達成 5 倍於 Transformer 之推論吞吐量，同時在 Language Modeling 上首次實現線性時間複雜度與 Transformer 等級之性能雙重目標。

#### 3.3.2 視覺 SSM 之二維擴展：VMamba 與 Vision Mamba

然而，Mamba 原生演算法係針對 1D 序列設計。將其應用於 2D 視覺數據之關鍵挑戰在於：(1) 視覺數據缺乏自然序列順序，(2) 需要位置感知 (Position Awareness) 以捕捉空間對稱性。

Liu 等人 [7] 提出之 VMamba 引入「2D Selective Scan (SS2D)」機制，透過四向平行掃描 (Top-Left  $\rightarrow$  Bottom-Right、Top-Right  $\rightarrow$  Bottom-Left 等) 將 1D 選擇性掃描推廣至 2D。VMamba 在 ImageNet-1K 達成 83.9% Top-1 準確率，超越 Swin Transformer [8] 0.4%，同時吞吐量超過 40%。在 COCO object detection 上，VMamba-Base 相較 Swin 提升 2.3% mAP，關鍵優勢為計算複雜度隨影像解析度呈線性成長 (不同於 ViT 之二次方成長)。

Zhu 等人 [10] 之 Vision Mamba (Vim) 採用雙向 SSM 與位置嵌入，在  $1248 \times 1248$  高解析度影像推論中較 DeiT 快 2.8 倍、GPU 記憶體節省 86.8%。該研究直接驗證了 SSM 在視覺稠密預測 (Dense Prediction) 任務上之可行性。

#### 3.3.3 本計畫之創新定位

相較於 VMamba/Vision Mamba 之通用視覺骨幹設計，本計畫之「2D Rot-SSM」著重於結構化數值穩定性保證與臨床解釋性，針對醫療影像邊緣部署之特殊需求：

1. **數值穩定性的結構保證**：VMamba/Vim 未明確處理有限精度量化下之極點偏移風險。本計畫透過 Rot-IIR 重參數化，將系統極點半徑  $\rho$  強制約束於  $\rho < 1$ ，確保 BIBO 穩定性，使模型在 16-bit 或 8-bit 邊緣設備上具備可重現性。
2. **病理特徵之頻域可解釋性**：本計畫將訓練權重還原為極點分布與二維頻譜響應，使 AI 決策與臨床 ABCD 法則形成科學對應 (如高頻極點對應邊緣碎裂紋理)，解決醫療 AI 之黑盒問題。VMamba/Vim 之特徵可視化 (如激活熱圖) 缺乏物理意義解釋。

### 3.4 有限字長 (FWL) 效應與 IIR 濾波器設計

Ko 等人 [5] 指出，IIR 濾波器在固定點實現時，係數量化導致之系統極點偏移為關鍵隱憂。傳統級聯型 IIR 濾波器 (Cascade Biquad) 因對量化誤差敏感，易產生零輸入極限環 (Zero-Input Limit Cycle, ZILC) 與輸出發散。該論文提出之「正規型相似轉換」 (State-Space Normal-Form Similarity Transformation) 方法，能將任意極點不同之 IIR 濾波器變換至對角化區塊形式，大幅降低動態範圍 (Dynamical Range) 問題。修正之耦合型濾波器 (Modified Coupled-Form) 在保持運算效率 ( $3n$  至  $3.5n$  次乘法) 同時消除 ZILC。

本計畫之核心創新在於將此一 IIR 穩定性設計範式應用至深度 SSM 的遞迴核：透過相似轉換矩陣  $\mathbf{T}$  將動態系統  $\mathbf{A}$  正規化，確保所有極點集中於高穩定區域內，從根本上防止遞迴運算之數值發散。此一設計在醫療診斷系統中至關重要——一旦極點偏移造成系統失穩，診斷結果將失去臨床可信度。

### 3.5 數據工程與臨床評估基準

ISIC 2019 Challenge 發布 25,331 張臨床標註皮膚病灶影像。相較 HAM10000 (10,015 張) [9] 之單一語言/地域偏好，ISIC 2019 涵蓋 8 個主要診斷類別、來自多國臨床中心，且包含 369 位獨立病患。本計畫採用患者層級 (Patient-wise) 五折交叉驗證嚴格防止數據洩漏，該方法論已成為皮膚科 AI 研究之標準實踐。

### 3.6 文獻探討小結

綜合上述文獻，當前在皮膚病變 AI 診斷領域存在以下技術斷層：

- (1) **感受野 vs. 複雜度的困境**：CNN 感受野有限，ViT 之  $O(N^2)$  複雜度對醫療邊緣部署不友善。SSM 提供線性複雜度解決方案，但現有視覺 SSM (VMamba/Vim) 未針對醫療應用之數值穩定性進行設計。
- (2) **黑盒問題**：深度學習模型之特徵學習過程缺乏物理解釋。VMamba/Vim 之激活視覺化無法直接對應臨床 ABCD 法則。
- (3) **邊緣部署之穩健性缺陷**：Mamba 類架構輸入相依設計在有限精度量化下易發生極點偏移，現有論文 (包括 Mamba 原始文獻) 未深入探討此一風險。本計畫藉由 Rot-IIR 重參數化與 IIR 設計經驗，填補此一斷層。

本計畫之 2D Rot-SSM 正是此一技術需求之結合體：繼承 SSM 之線性複雜度與高效運算，結合 IIR 之結構化穩定性設計，並透過頻域解釋提升臨床可信度。

## 四、研究方式及步驟

本計畫旨在構建一個具備數值強健性與病理可解釋性之「二維旋轉狀態空間模型 (2D Rot-SSM)」，用於自動化判讀皮膚病變影像。研究流程將結合大規模臨床數據工程、線性系統離散化推導、以及系統穩定性優化理論。以下詳述本研究之四個關鍵實作階段。

### 4.1 階段一：基於臨床後設數據之層級化數據工程 (Clinical Data Engineering)

本研究採用之數據源為 ISIC 2019 Challenge 訓練集，共包含 25,331 張經臨床標記之皮膚病灶影像。針對數據之高維度與不對稱性，執行以下流程：

4.1.1 病患層級之五折交叉驗證分割 (Patient-wise Stratification)

在傳統影像分類任務中，簡單的隨機分割 (Random Split) 常導致「數據洩漏 (Data Leakage)」問題。由於 ISIC 2019 數據集包含 369 位病患，多張影像可能來自同一病患之不同部位。本計畫依據後設數據 (metadata.csv) 中之 patient\_id 與 lesion\_id 進行數據分割：

- **五折交叉驗證 (5-fold CV)**：將病患 ID 作為分割單位，確保訓練集、驗證集與測試集之間完全不包含相同病患。
- **泛化性能驗證**：此機制能確保模型學習的是通用的病理特徵（如黑色素瘤之細胞結構），而非特定病患之皮膚背景特質。

表 2： ISIC 2019 訓練集之真實臨床數據統計表 (n=25,331)

| 項目 (Metadata Item)             | 統計數值         | 佔比/說明         |
|--------------------------------|--------------|---------------|
| 總影像數 (Total Images)            | 25,331       | 100%          |
| 獨立病灶數 (Unique Lesions)         | 12,264       | 平均每個病灶約 2 張圖  |
| <b>獨立病患數 (Unique Patients)</b> | <b>369</b>   | <b>關鍵分割單位</b> |
| 平均每人影像數 (Avg. Images/Patient)  | <b>68.65</b> | <b>高度重疊風險</b> |
| 診斷分佈 (Diagnosis 1)             |              |               |
| - 良性 (Benign)                  | 15,990       | 63.12%        |
| - 惡性 (Malignant)               | 8,473        | 33.45%        |
| - 未定 (Indeterminate)           | 868          | 3.43%         |
| 金標準確認 (Confirmation)           |              |               |
| - 組織病理切片 (Histopathology)      | 17,049       | 67.31%        |
| - 追蹤與專家共識 (Others)             | 8,282        | 32.69%        |




圖 2：病患層級五折交叉驗證流程圖。透過 patient\_id 分組確保驗證集之獨立性。

#### 4.1.2 診斷標籤之精煉與不平衡處理

本研究利用 diagnosis\_1 至 diagnosis\_5 之階層標註。針對臨床篩檢需求，實作二元分類映射：

- 將 Malignant (包含 Melanoma, Basal cell carcinoma, Squamous cell carcinoma) 標記為正樣本 1.0。
- 將 Benign (包含 Nevus, Seborrheic keratosis, Dermatofibroma) 標記為負樣本 0.0。

針對樣本分布極度不均之問題 (如黑色素瘤比例較低)，採用「加權隨機採樣 (Weighted Random Sampling)」與「Focal Loss[6]」損失函數，提升模型對惡性病變之敏感度。

#### 4.1.3 線性代數域之影像預處理

影像統一縮放至  $128 \times 128$  像素，並執行均值與標準差歸一化。從線性代數觀點，將像素張量轉換為  $\mathbf{x} \in [0, 1]^{C \times H \times W}$ ，能確保輸入信號在通過狀態空間算子時，隱藏狀態  $\mathbf{h}_k$  不致產生數值溢位。

### 4.2 階段二：2D Rot-SSM 核心架構與四向掃描之理論建構

本階段將傳統一維狀態空間模型擴展至二維視覺領域。本研究之核心創新在於將 SSM 之動態算子定義為具備物理語義之「Rot-IIR 動態原子」，並結合旋轉不變性。

#### 4.2.1 基於 Rot-IIR 之狀態空間離散化

定義連續時間系統方程中，系統矩陣  $\mathbf{A}$  具備旋轉結構。利用「零階保持 (ZOH)」技術離散化後，其隱藏狀態  $\mathbf{h}_k$  之遞迴公式為：

$$\mathbf{h}_k = \bar{\mathbf{A}}(\rho, \theta)\mathbf{h}_{k-1} + \bar{\mathbf{B}}(\rho, \theta, g)\mathbf{x}_k \quad (1)$$

其中，本研究直接將系統參數化為極點半徑  $\rho$ 、頻率角度  $\theta$  與增益  $g$ 。此設計賦予模型  $O(N)$  的線性複雜度，使其能高效處理 ISIC 2019 大規模影像數據。

#### 4.2.2 四向平行掃描機制 (SS2D Parallel Scanning)

為捕捉病灶之二維空間依賴，本研究實作具旋轉不變性之「ParallelRotSSM2D」模組 (如圖 3 所示)。該模組透過 \*\*Pseudo-separable (偽分離)\*\* 架構，將影像展開為四條並行掃描路徑。此機制能精確對應病灶臨床特徵中之「邊緣不規則性 (Border)」與「全域對稱性 (Asymmetry)」，以極低運算成本完成全域感知。




圖 3：2D Rot-SSM 架構流程圖。本圖展示由  $1022 \times 767$  影像預處理至最終惡性機率判讀之完整線性運算流程。

### 4.3 階段三：結構化穩定性保證與極點診斷理論

不同於傳統 SSM 需透過繁瑣的相似轉換尋找穩定實現，本研究引入老師提出之「結構化穩定性」設計，從根本解決醫療設備在有限精度實現下之數值發散風險。

#### 4.3.1 Rot-IIR 重參數化與 BIBO 穩定性


本研究透過重參數化技術 (Reparameterization)，將系統極點半徑  $\rho$  約束於穩定域內。令  $\rho = \sigma(\hat{\rho}) \cdot \rho_{max}$ ，其中  $\sigma$  為 Sigmoid 函數且  $\rho_{max} = 0.995$ 。此結構化約束保證了系統具備絕對之「有界輸入有界輸出 (BIBO)」穩定性。如圖 4 所示，無論訓練初期權重如何擺動，系統極點皆能被強制約束於安全半徑內。

#### 4.3.2 具備物理語義之極點診斷

在此參數化架構下，模型之每一層皆具備清晰之頻域特徵。頻率角度  $\theta$  直接對應影像之空間頻率分布：

- **低角度** ( $\theta \approx 0$ )：捕捉病灶內部之色彩一致性與低頻平滑區域。
- **高角度** ( $\theta \approx \pi$ )：對應病灶邊緣之碎裂紋理與微細特徵。

這種「原生解釋性」使本研究不僅能在 16-bit 運算下維持高度強健性，更能將 AI 之抽象權重轉化為醫師可理解之病理指標。



(a) 未優化之系統矩陣  $\mathbf{A}$  極點分布。極點散落，部分位於單位圓外或邊界附近，導致數值不穩定風險。

(b) 經相似轉換  $\mathbf{T}^{-1}\mathbf{A}\mathbf{T}$  優化後之極點分布。所有極點成功收斂至單位圓內之高穩定目標區域。

圖 4：2D Rot-SSM 系統穩定性優化前後之  $z$  平面極點分布對照圖。左圖顯示原始 SSM 算子因參數初始化或訓練過程可能導致極點發散；右圖展示引入本研究提出之相似轉換矩陣  $T$  後，強制將所有系統極點約束於安全半徑  $\rho_{max}$  內，確保了模型在長序列遞迴運算下的數值穩定性。

## 4.4 階段四：大規模平行訓練與臨床頻域解釋性分析

### 4.4.1 HPC 異質計算環境訓練

本計畫利用校內高效能運算 (HPC) 資源，配置 NVIDIA GPU 執行大規模參數優化。

- **優化器設定**：採用 AdamW 結合 Cosine Decay 調度器，設定初始學習率  $2e-3$ 。
- **收斂監控**：利用 AUC-ROC 曲線實時監控 25,331 張影像在不同病患分割下的收斂狀況。

### 4.4.2 二維頻譜與極點可視化解釋 (Explainability)

不同於傳統神經網路之「黑盒」特性，2D Rot-SSM 可透過線性系統頻譜進行物理診斷。

- **極點分布圖 (Pole Plot)**：透過 `plot_2d_poles_and_spectrum` 函數，繪製每一層 SSM 區塊之特徵值分布。若極點傾向於  $\theta \approx 0$  (低頻)，代表模型正關注病灶之色彩一致性；若極點傾向於高角度 (高頻)，代表模型正偵測病灶邊緣之碎裂紋理。
- **空間過濾器分析**：將學得之參數還原為 2D 頻率響應  $|H(\omega_h, \omega_w)|$ ，為臨床醫師提供具備訊號處理依據之解釋報告，提升醫療診斷之可信度。

## 4.5 執行進度與里程碑 (Timeline and Milestones)

本計畫為期八個月，研發流程分為三個核心階段，旨在達成從數學建模、數值穩定性驗證到終端診斷應用之完整鏈接：

### • 第一階段：理論架構與基礎建模 (第 1-2 個月)

完成 2D Rot-IIR 算子之穩定性重參數化設計，並實作 \*\*Pseudo-separable (偽分離)\*\* 四向掃描架構。建立基礎訓練流水線，完成 ISIC 2019 數據集之層級化數據工程，確保模型具備初步學習能力。

- **第二階段：數值診斷、穩定性優化與後端開發（第 3-5 個月）**  
開發「極點分布診斷工具」，即時監控訓練中之動態核行為。執行 \*\* 有限精度（FP16/BF16）一致性驗證 \*\*，評估模型在邊緣運算環境下之誤差擴散狀況。同時，同步開發後端推理引擎，為後續之互動式診斷介面奠定運算基礎。
- **第三階段：系統整合、臨床互動介面與驗證（第 6-8 個月）**  
完成 2D Rot-SSM 之模型封裝。本階段重點為開發「\*\* 具備臨床解釋性之智慧診斷系統原型（GUI）\*\*」，實作使用者端影像上傳、即時病灶判讀與自動化特徵分析功能。系統將整合穩定性診斷指標與極點域可視化數據，提供醫師具備物理依據之決策參考。




圖 5：2D Rot-SSM 皮膚病變輔助診斷計畫執行時程表。

## 五、預期結果

本計畫預期透過「二維旋轉狀態空間模型（2D Rot-SSM）」之建構與優化，在皮膚病變影像之自動化篩檢領域，達成運算效能、數值穩定性與臨床解釋性之全面突破。以下就四個核心維度詳述本研究之預期成果：

### 5.1 皮膚病灶辨識效能之量化指標提升

本研究利用 ISIC 2019 大規模數據集進行訓練，預期在診斷效能上達成以下目標：

- 全域特徵擷取精準度**：預期模型在惡性黑色素瘤與良性病變之二元分類任務中，其 AUC-ROC 將穩定達到 0.85 以上。憑藉 2D Rot-SSM 之全域感應野特質，預期在處理邊緣彌散或形狀高度非對稱之病灶時，能展現優於傳統 CNN 之敏感度 (Sensitivity)。

- (b) **多向空間特徵感知**：透過四向平行掃描機制，模型預期能更精確地捕捉基底細胞癌 (BCC) 特有的珍珠狀邊緣與細微紋理，提升對 `metadata.csv` 中定義之八類病灶的多類別判讀能力。

## 5.2 結構化數值穩定性與邊緣部署強健性

本研究之核心理論貢獻在於解決 Mamba 類模型在硬體部署時之數值不穩定風險：

- (a) **絕對穩定性之結構保證**：透過 Rot-IIR 重參數化技術，預期將系統極點半徑  $\rho$  鎖定於安全範圍內。相較於未受約束之原始 SSM 架構，本模型將具備絕對之 **\*\*BIBO 穩定性\*\***，確保在連續推理過程中隱藏狀態不致產生數值溢位。
- (b) **低位元運算下之性能保全**：在模擬 16-bit 甚至 8-bit 定點數之量化環境下，預期本模型之 AUC 損失將顯著小於 Mamba-2 或 Transformer。即便在有限精度 (FWL) 環境下，診斷結果仍能維持與高精度工作站一致之精準度。

## 5.3 臨床特徵之可解釋性與頻域診斷工具

本計畫旨在將 AI 的抽象特徵轉化為醫師可理解的物理指標：

- (a) **極點語義與病理特徵映射**：預期產出之極點分布圖能與臨床 ABCD 法則形成科學對應 (如高頻極點對應邊緣不規則性)，輔助醫師理解模型決策依據，解決醫學 AI 之「黑盒」問題。
- (b) **二維空間頻譜響應報告**：針對每一張輸入影像，系統能產出其特徵響應圖，視覺化呈現模型關注之病灶對稱性或色素沉著特徵。

## 5.4 臨床輔助診斷系統原型 (GUI) 與軟體產出

本計畫預期將研究成果轉化為具備互動性之臨床工具：

- (a) **互動式智慧診斷介面**：開發一組具備臨床解釋力之軟體原型。使用者可上傳臨床影像，系統將執行即時病灶判讀，並同步顯示極點分布、特徵熱圖與診斷機率，達成 AI 決策透明化。
- (b) **開源貢獻**：實作之 2D-Rot-SSM 核心算子與穩定性診斷工具箱將進行開源，為高穩定性醫療 AI 之開發提供關鍵之理論支撐與實務範本。

## 參考文獻

- [1] Alexey Dosovitskiy et al. "An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale". In: *International Conference on Learning Representations (ICLR)* (2021).
- [2] Andre Esteva et al. "Dermatologist-level classification of skin cancer with deep neural networks". In: *Nature* 542.7639 (2017), pp. 115-118.
- [3] Albert Gu and Tri Dao. "Linear-Time Sequence Modeling with Selective State Spaces". In: *First Conference on Language Modeling (COLM)* (2024).
- [4] Albert Gu, Karan Goel, and Christopher Re. "Efficiently Modeling Long Sequences with Structured State Spaces". In: *arXiv preprint arXiv:2111.00396* (2021).

- [5] Hsien-ju Ko et al. "Performance Evaluation of Infinite Impulse Response Filter Synthesis Using Parallel-Direct-Ladder Form under Finite Word-Length Effects". In: *Signal Processing* 210 (2023), p. 109065.
- [6] Tsung-Yi Lin et al. "Focal Loss for Dense Object Detection". In: *International Conference on Computer Vision (ICCV)* (2017).
- [7] Yue Liu et al. "VMamba: Visual State Space Model". In: *Advances in Neural Information Processing Systems (NeurIPS)* 37 (2024), pp. 103031-103063.
- [8] Ze Liu et al. "Swin Transformer: Hierarchical Vision Transformer using Shifted Windows". In: *International Conference on Computer Vision (ICCV)* (2021).
- [9] Philipp Tschandl, Cliff Rosendahl, and Harald Kittler. "The HAM10000 dataset, a large collection of multi-source dermatoscopic images of common pigmented skin lesions". In: *Scientific Data* 5 (2018), pp. 1-9.
- [10] Lianghui Zhu et al. "Vision Mamba: Efficient Visual Representation Learning with Bidirectional State Space Model". In: *arXiv preprint arXiv:2401.09417* (2024).